

AGROGEN IA

Matriz de Inteligência Artificial

Documento Técnico Completo — Construção, Arquitetura, Análise e Operação do Componente de IA

Abordagens · Engenharia de Dados · Scoring · MLOps · Outputs · Riscos · Implementação

Versão 1.0 · Junho de 2026

Hackathon Expoagro Crateús 2026

Equipe AgroGen IA — Crateús, CE

Sumário Executivo

Este documento consolida toda a especificação do componente de Inteligência Artificial do AgroGen IA — sistema de gestão genética e reprodutiva de bovinos, ovinos e caprinos desenvolvido para o Hackathon Expoagro Crateús 2026. A Matriz de IA aqui descrita é normativa: governa as decisões de arquitetura, os dados de treinamento, o motor de scoring, o pipeline de MLOps, os entregáveis ao usuário final e a gestão dos riscos associados ao uso de IA em decisões agropecuárias.

Premissas estratégicas

- Arquitetura híbrida combinando Machine Learning supervisionado (Random Forest), motor de regras determinístico (fallback) e clustering não supervisionado (K-Means para padrões).
- Operação resiliente: o sistema sempre responde — se o modelo de ML falha, o motor de regras assume automaticamente.
- Explicabilidade obrigatória: toda predição vem acompanhada dos top-5 fatores determinantes em linguagem técnica acessível.
- Aviso clínico inegociável: nenhuma predição substitui o julgamento veterinário; o aviso é injetado no backend e não pode ser ocultado pelo frontend.
- Aprendizado contínuo: cada diagnóstico de gestação registrado realimenta o dataset; o modelo é retreinado a cada três meses ou 500 novos registros.
- Cold start sólido: dataset inicial de 1.300 registros sintéticos calibrados por literatura zootécnica (EMBRAPA GENECOC, Hafez 2004) e validados por veterinário consultor.

Métricas-alvo do modelo

Métrica	Alvo	Critério
Acurácia	> 75%	Conjunto de teste estratificado (20% do dataset)
AUC-ROC	> 0,80	Validação cruzada com 5 folds
F1-score (classe PRENHA)	> 0,78	Métrica primária — equilibra precisão e recall
Latência por inferência	≤ 1.000 ms	P95; meta interna 500 ms
Disponibilidade	≥ 99%	Inclui fallback automático para motor de regras

1. Abordagens de IA e Arquitetura

1.1 Visão geral da estratégia

O AgroGen IA adota uma arquitetura híbrida de inteligência artificial, combinando três técnicas complementares que se reforçam mutuamente. A escolha por uma abordagem múltipla — em vez de

uma única técnica monolítica — atende a três restrições do projeto: (1) o requisito do edital de implementar IA em ao menos uma das três frentes (predição, padrões, recomendação); (2) a necessidade de operar em condições adversas do sertão (baixa conectividade, dados esparsos no cold start); e (3) a exigência regulatória de explicabilidade junto a usuários técnicos da pecuária (veterinários e zootecnistas).

1.2 Técnicas adotadas

Machine Learning Supervisionado — Random Forest

Núcleo da Predição de Prenhez. Algoritmo de ensemble baseado em árvores de decisão, escolhido pela sua robustez a overfitting, capacidade de lidar com dados tabulares mistos (numéricos e categóricos), tolerância a valores ausentes e — fundamental para o contexto — pela interpretabilidade via feature importance. Cada predição vem acompanhada da contribuição relativa de cada variável, permitindo ao veterinário entender e contestar o resultado. Implementação em Python com scikit-learn, exposto como microserviço REST consumido pelo backend Java/Spring Boot.

Motor de Regras Determinístico (Rules-Based Engine)

Implementado em Java dentro do próprio backend Spring Boot. Funciona como baseline auditável e, principalmente, como fallback caso o microserviço Python esteja indisponível. As regras encapsulam o conhecimento zootécnico consolidado (faixas ideais de condição corporal, intervalos pós-parto mínimos, penalizações por estresse calórico) e são derivadas da literatura de referência (EMBRAPA GENECOC, Hafez 2004). Garante que o sistema sempre devolva uma resposta tecnicamente defensável, mesmo sem o modelo de ML carregado.

Clustering Não Supervisionado — K-Means

Usado na frente de Padrões de Fertilidade. Agrupa o rebanho em coortes com perfis reprodutivos similares, revelando padrões que não seriam evidentes em análises univariadas. Output: insights descritivos do tipo "Animais com CC entre 3 e 4 inseminados em meses chuvosos têm taxa de prenhez 23% superior".

1.3 Comparativo das técnicas no projeto

Técnica	Frente	Tipo	Stack	Justificativa principal
Random Forest	Predição de Prenhez	Supervisionado	Python + scikit-learn	Robusto, interpretável, eficiente em dados tabulares
Motor de Regras	Predição (fallback)	Determinístico	Java + Spring Boot	Resiliência, auditabilidade, baseline
K-Means	Padrões de Fertilidade	Não supervisionado	Python + scikit-learn	Revela coortes sem rótulos

Técnica	Frente	Tipo	Stack	Justificativa principal
Regras + Scoring	Seleção Genética	Determinístico	Java + Spring Boot	Ranking transparente baseado em DEPs

1.4 O que foi explicitamente descartado

Modelos de Linguagem (LLMs) como motor preditivo

Descartados como componente central do motor preditivo. A justificativa é dupla: (i) o problema central — predição de taxa de prenhez — é fundamentalmente um problema de classificação binária sobre dados tabulares estruturados, domínio em que algoritmos clássicos de ML superam consistentemente LLMs em acurácia, custo e latência; (ii) LLMs introduzem risco de alucinação inaceitável em um contexto de decisão sanitária e econômica para pequenos produtores.

Uso futuro avaliável (v1.1+)

Roadmap pós-MVP


Camada de explicação em linguagem natural usando LLM pode ser avaliada na v1.1, com guardrails restritos (templates aprovados, allowlist de saída, opt-out fácil). No MVP, recomendações são geradas por templates determinísticos preenchidos com resultados numéricos do modelo.


PLN sobre dados textuais

Não aplicável neste estágio. Os campos textuais do sistema (observações de inseminação, descrição de ocorrências) são livres mas pouco volumosos. Em versão futura, pode-se aplicar análise de sentimento ou extração de entidades para identificar padrões em ocorrências sanitárias (ex: surtos de mastite reportados em texto livre).

1.5 Diagrama lógico da arquitetura de IA

A requisição de predição segue o seguinte caminho:





1.6 Stack tecnológica do componente de IA

Camada	Tecnologia	Justificativa
Treinamento do modelo	Python 3.11, scikit-learn 1.4, pandas, numpy	Padrão de mercado para ML tabular; comunidade ativa
Serialização do modelo	joblib (formato .pkl)	Compatibilidade nativa com scikit-learn; carregamento rápido
Servir o modelo	FastAPI 0.110 + Uvicorn	Latência baixa; tipagem nativa via Pydantic; docs automáticas
Motor de regras (fallback)	Java 17 + Spring Boot 3.x	Mesma stack do backend principal; deploy unificado
Comunicação backend ↔ ML	REST/JSON síncrono com timeout 800 ms	Simplicidade; suficiente para SLA de 1 segundo
Versionamento de modelo	Identificador semântico no JSON de resposta	Rastreabilidade de qual modelo gerou cada predição
Armazenamento de datasets	CSV versionados em repositório auxiliar	Reprodutibilidade dos treinamentos; não polui banco operacional
Análise exploratória (offline)	Jupyter Notebook + matplotlib + seaborn	Visualizações e iteração rápida durante desenvolvimento
Tracking de experimentos	MLflow (opcional v1.1)	Pós-MVP — comparar runs de treinamento

2. Engenharia de Dados e Contexto

2.1 Fontes de dados

Os dados que alimentam o modelo de IA têm três origens distintas, todas sob a alçada do próprio sistema AgroGen IA — não há dependência de fontes externas no MVP, o que protege a operação contra indisponibilidade de terceiros.

Fonte	Tipo	Volume típico	Uso
Banco operacional (PostgreSQL 15)	Histórico estruturado	Cresce com uso (animais × inseminações × pesagens)	Features históricas em tempo de inferência
Formulário de predição	Entrada manual do usuário	4-6 campos por chamada	Variáveis situacionais (CC atual, temperatura, protocolo planejado)
Dataset cold start	CSV sintético versionado	1.300 registros	Treinamento inicial antes do primeiro deploy
Dataset de retreino	Pares feature-target reais	Acumula no banco (tb_predicao_log + diagnóstico)	Realimentação a cada 3 meses ou 500 registros

2.2 Pipeline de ingestão e limpeza no momento da inferência

No momento da inferência, o backend executa o seguinte fluxo de preparação de dados:

Etapa 1 — Extração

Consulta SQL que recupera o animal-alvo, seu histórico reprodutivo (últimas 10 inseminações com diagnósticos), suas pesagens (últimas 6), seu último parto, seus dados genéticos e seu coeficiente de endogamia calculado. Tempo médio: 120 ms para fazendas com até 500 animais, graças aos índices em `fazenda_id` e `animal_id`.

Etapa 2 — Derivação de variáveis calculadas

- `dias_pos_parto` = `data_proposta` – `data_ultimo_parto`
- `dias_desde_ultima_ins` = `data_proposta` – data da última inseminação
- `historico_taxa_prenhez` = `prenhez confirmadas` ÷ `inseminações totais do animal`
- `ciclos_sem_concepcao` = sequência de resultados VAZIA desde a última PRENHA
- `heterose_esperada` = cálculo a partir das raças da fêmea e do reprodutor

Etapa 3 — Tratamento de ausências

Campos numéricos faltantes são preenchidos com a mediana do rebanho da mesma espécie. Campos categóricos com a moda. Para animais primíparas (sem partos anteriores), o campo `historico_taxa_prenhez` assume a média da raça quando disponível, ou a média global do rebanho como último recurso.

Etapa 4 — Codificação categórica

Espécie, raça, tipo de inseminação, protocolo hormonal e estação do ano são convertidos via one-hot encoding. Variáveis numéricas (peso, condição corporal, temperatura, intervalos em dias) passam por normalização `MinMaxScaler` usando os parâmetros aprendidos no treinamento.

Etapa 5 — Validação de range (defesa)

Valores absurdos (peso negativo, temperatura acima de 50°C, `dias_pos_parto` negativos) acionam exceção e o sistema retorna erro 422 ao invés de gerar predição duvidosa. Essa salvaguarda evita que erros de entrada se propaguem como predições aparentemente válidas.

2.3 Janela de Contexto enviada ao modelo

A janela de contexto é o conjunto de informações empacotadas e enviadas ao motor de ML em cada inferência. Define-se em cinco grupos:

Grupo A — Contexto do animal-alvo

Campo	Tipo	Origem
<code>especie</code>	enum	<code>tb_animal</code>
<code>sexo</code>	enum (sempre F)	<code>tb_animal</code>
<code>raca_femea</code>	string	<code>tb_dados_geneticos</code>
<code>idade_meses</code>	int	derivado de <code>data_nascimento</code>
<code>peso_atual_kg</code>	decimal	última pesagem em <code>tb_pesagem</code>
<code>condicao_corporal</code>	int (1-5)	input do usuário (override do banco)
<code>num_partos</code>	int	<code>tb_animal.num_partos</code>
<code>data_ultimo_parto</code>	date	<code>tb_animal.data_ultimo_parto</code>
<code>status</code>	enum	<code>tb_animal.status</code>

Grupo B — Contexto genético

Campo	Tipo	Origem
dep_peso_desmame	decimal	tb_dados_geneticos
dep_fertilidade	decimal	tb_dados_geneticos
dep_acuracia	decimal	tb_dados_geneticos
coeficiente_endogamia	decimal	tb_dados_geneticos
raca_pai	string	tb_dados_geneticos
raca_mae	string	tb_dados_geneticos
percentual_sangue	string	tb_dados_geneticos (opcional)

Grupo C — Contexto histórico reprodutivo

Campo	Tipo	Origem
num_inseminacoes_total	int	COUNT em tb_inseminacao
historico_taxa_prenhez	decimal	derivado: prenhes / total
ciclos_sem_concepcao	int	derivado da sequência de resultados
data_ultima_inseminacao	datetime	MAX(data) em tb_inseminacao
tipo_ultima_inseminacao	enum	tb_inseminacao
resultado_ultima_inseminacao	enum	tb_diagnostico_gestacao
intervalo_entre_2_ultimas	int	derivado

Grupo D — Contexto reprodutor candidato

Campo	Tipo	Origem
reprodutor_raca	string	tb_reprodutor
reprodutor_dep_peso	decimal	tb_reprodutor
reprodutor_dep_fertilidade	decimal	tb_reprodutor
reprodutor_dep_acuracia	decimal	tb_reprodutor
reprodutor_tipo	enum	tb_reprodutor (SEMEN_EXTERNO ANIMAL_PROPRIO)
heterose_esperada	decimal	derivado: cruzamento raca_femea × reprodutor_raca

Grupo E — Contexto situacional

Campo	Tipo	Origem
temperatura_ambiente_c	decimal	input do usuário
estacao	enum	derivado da data (SECA CHUVOSA)
tipo_inseminacao	enum	input do usuário (IA_CONV IATF TE)
protocolo_hormonal	string	input do usuário (texto livre)
tecnico_id	UUID	usuário logado
tecnico_taxa_historica	decimal	derivado: prenhez gerada por este técnico no rebanho

Resumo: 14 features ativas no MVP

O conjunto foi calibrado para equilibrar capacidade preditiva com simplicidade de coleta — o produtor não precisa preencher mais que três campos manualmente; o restante é derivado automaticamente do banco. A janela de contexto é serializada como JSON e enviada no body da requisição ao microsserviço Python. Tamanho médio da carga: 1,2 KB, dentro da margem confortável para latência sub-segundo.

2.4 Exemplo do JSON de contexto enviado ao modelo

POST /predicao (microsserviço Python)

```
{
  "predicao_id": "uuid-temp-para-tracking",
  "animal_id": "550e8400-e29b-41d4-a716-446655440000",
  "contexto_animal": {
    "especie": "BOVINO",
    "raca_femea": "Nelore",
    "idade_meses": 60,
    "peso_atual_kg": 420,
    "condicao_corporal": 4,
    "num_partos": 3,
    "intervalo_pos_parto_dias": 90
  },
  "contexto_genetico": {
    "dep_fertilidade": 8.2,
    "dep_acuracia": 0.72,
    "coeficiente_endogamia": 0.012
  },
  "contexto_historico": {
    "num_inseminacoes_total": 4,
    "historico_taxa_prenhez": 0.75,
    "ciclos_sem_concepcao": 1,
    "dias_desde_ultima_ins": 35
  },
  "contexto_reprodutor": {
    "reprodutor_raca": "Angus",
    "reprodutor_dep_fertilidade": 7.5,
    "reprodutor_dep_acuracia": 0.88,
    "heterose_esperada": 4.2
  },
}
```

```

"contexto_situacional": {
  "temperatura_ambiente_c": 29,
  "estacao": "SECA",
  "tipo_inseminacao": "IATF",
  "protocolo_hormonal": "P4+EB 7 dias"
}
}

```

3. Processamento e Regras de Scoring

3.1 Fórmula de Scoring (Baseline determinístico)

O Motor de Regras determinístico opera com uma fórmula aditiva sobre uma probabilidade base, ajustada por deltas calculados feature a feature. Esta fórmula serve a três propósitos: (i) é o fallback do sistema quando o microserviço de ML está indisponível; (ii) é o baseline contra o qual o Random Forest é avaliado em cada novo treinamento; (iii) é a fórmula auditável que pode ser explicada a um veterinário cético em linguagem zootécnica.

Fórmula geral

Score Final

Score = Probabilidade Base + Σ Deltas + Ruído de Realismo

Componentes da fórmula

A Probabilidade Base depende da espécie e reflete a taxa de prenhez média histórica da literatura:

Espécie	Probabilidade Base	Fonte
Bovinos	60%	Média nacional ajustada · EMBRAPA / Hafez 2004
Ovinos	65%	Literatura zootécnica · raças adaptadas
Caprinos	65%	Literatura zootécnica · raças adaptadas

Esses valores são parametrizáveis via tabela de configuração no banco (tb_regras_scoring) — não estão hardcoded. Toda alteração é logada na trilha de auditoria com data, usuário e valor anterior.

A Soma dos Deltas é o somatório dos ajustes positivos e negativos aplicados por cada feature (detalhados em 3.3). O delta pode ser positivo (favorece a prenhez) ou negativo (penaliza). A soma é truncada para garantir que o score final fique no intervalo válido [0, 1].

O Ruído de Realismo é uma pequena variação aleatória de ± 2 pontos percentuais, aplicada apenas no fallback do motor de regras. Existe para evitar que o sistema entregue scores idênticos para animais com

histórico idêntico, o que comunicaria uma falsa precisão. No modelo Random Forest, essa variação não é necessária porque o modelo já tem variância natural.

Classificação qualitativa do score

Score	Classificação	Cor (UI)	Interpretação
≥ 0,70	Favorável	Verde	Momento adequado para inseminar; condições alinhadas
0,50–0,69	Médio	Amarelo	Há fatores de atenção; revisar antes de prosseguir
< 0,50	Desfavorável	Vermelho	Risco elevado; considerar adiar ou ajustar manejo

3.2 Seleção de Features

As 14 features do modelo foram selecionadas por triagem combinada de duas fontes: (i) literatura zootécnica de referência sobre fatores associados à eficiência reprodutiva; (ii) análise de feature importance preliminar sobre o dataset de cold start. Apenas as variáveis com importância relativa superior a 3% no Random Forest baseline foram mantidas.

Feature	Tipo	Importância	Razão da seleção
condicao_corporal	Numérica (1-5)	Alta	CC ideal (3-4) correlaciona fortemente com concepção
historico_taxa_prenhez	Numérica (0-1)	Alta	Histórico individual é o melhor preditor de resultado
intervalo_pos_parto_dias	Numérica (dias)	Alta	Abaixo de 45 dias compromete fertilidade severamente
num_partos_anteriores	Numérica (int)	Alta	Primíparas e vacas velhas têm taxas reduzidas
dias_desde_ultima_ins	Numérica (dias)	Alta	Inseminar antes do ciclo completo penaliza fortemente
dep_fertilidade_animal	Numérica decimal	Média	DEP é estimador genético validado
especie	Categórica	Média	Taxas base diferentes por espécie
raca_femea	Categórica	Média	Raças adaptadas ao sertão têm vantagem
tipo_inseminacao	Categórica	Média	IATF tem ganho médio sobre IA convencional
protocolo_hormonal	Categórica	Média	P4+EB e Ovsynch melhoram taxas
temperatura_ambiente	Numérica (°C)	Média	Acima de 34°C causa estresse calórico

Feature	Tipo	Importância	Razão da seleção
_c			documentado
estacao	Categórica	Média	Seca vs chuvosa impacta nutrição e fertilidade
dep_acuracia	Numérica (0-1)	Baixa	Pondera a confiabilidade dos DEPs
coeficiente_endogamia	Numérica (0-1)	Baixa	F elevado reduz vigor reprodutivo

Features avaliadas e descartadas no MVP

- Dados climáticos extensos (pluviometria, umidade) — dependeriam de fonte externa
- Peso absoluto do animal — correlação fraca após controlar por condição corporal
- Identidade do técnico responsável — alta variabilidade e poucos dados por técnico no cold start (pode ser reintroduzida em retrainings futuros após coletar volume suficiente)
- Idade exata em meses — substituída pelo proxy num_partos_anteriores, que captura essencialmente a mesma informação com menor variância

3.3 Deltas por Variável

A tabela abaixo formaliza os deltas aplicados pelo Motor de Regras. Estes valores também servem como sanity check do Random Forest: se o modelo de ML aprender impactos radicalmente diferentes destes, há indício de overfitting ou dados enviesados, e o retreinamento é abortado.

Variável	Condição	Delta no Score
condicao_corporal	3,0 a 4,0 (ideal)	+10 pontos
condicao_corporal	2,5 ou 4,5	+3 pontos
condicao_corporal	< 2,5 ou > 4,5	-12 pontos
intervalo_pos_parto_dias	≥ 60 dias	+4 pontos
intervalo_pos_parto_dias	45 a 59 dias	0 (neutro)
intervalo_pos_parto_dias	< 45 dias	-15 pontos
num_partos_anteriores	0 (primípara)	-4 pontos
num_partos_anteriores	2 a 4	+6 pontos
num_partos_anteriores	≥ 7	-5 pontos
historico_taxa_prenhez	≥ 0,70	+8 pontos
historico_taxa_prenhez	0,40 a 0,69	0 (neutro)
historico_taxa_prenhez	< 0,40	-7 pontos

Variável	Condição	Delta no Score
dias_desde_ultima_ins (Bov)	< 21 dias	-10 pontos
dias_desde_ultima_ins (O/C)	< 17 dias	-10 pontos
dias_desde_ultima_ins	≥ ciclo da espécie	0 (neutro)
tipo_inseminacao	IATF com protocolo válido	+5 pontos
tipo_inseminacao	IA Convencional	0 (neutro)
temperatura_ambiente_c	18°C a 28°C	0 (neutro)
temperatura_ambiente_c	29°C a 33°C	-2 pontos
temperatura_ambiente_c	≥ 34°C	-8 pontos
raca_femea	Raça adaptada (Nelore, Santa Inês, Anglo-nubiano, Moxotó)	+4 pontos
raca_femea	Demais raças	0 (neutro)
heterose_esperada	≥ 4% (cruzamento entre raças distantes)	+4 pontos
coeficiente_endogamia (F)	> 0,0625 (consanguinidade)	-10 pontos
DEP fertilidade somada	≥ 12 (animal + reprodutor)	+6 pontos
dep_acuracia média	< 0,40 (DEPs pouco confiáveis)	metade do delta de DEP aplicado

Parametrização externa

Os deltas são parametrizados em uma tabela de configuração (tb_regras_scoring) no banco PostgreSQL, permitindo ajuste fino sem deploy de código. Toda alteração nessa tabela é logada na trilha de auditoria com data, usuário responsável e valor anterior. Em uma evolução pós-MVP, essa tabela pode ser exposta a um painel administrativo para que o veterinário consultor ajuste pesos baseado em observações de campo.

4. Pipeline de Treinamento e Evolução (MLOps)

4.1 Cold Start — treinamento inicial

O primeiro modelo é treinado antes do deploy do MVP, usando o dataset sintético de 1.300 registros calibrado conforme literatura zootécnica e validado por veterinário consultor do projeto.

Etapas do pipeline de cold start

Etapa 1 — Coleta

Consolidação do dataset em arquivo CSV versionado no repositório (datasets/cold_start_v1.csv). Cada linha representa uma inseminação histórica com 28 colunas (14 features ativas + 13 features auxiliares descartadas no MVP + 1 target binário). A composição respeita as taxas base reais por espécie (Bovinos 60%, Ovinos 65%, Caprinos 65%) e introduz correlações realistas entre features (animais com CC baixa também tendem a ter intervalo pós-parto curto, por exemplo).

Etapa 2 — Pré-processamento

Aplicação das transformações descritas na seção 2.2 sobre o dataset completo: tratamento de ausências, encoding categórico, normalização. O split é 80% treino, 20% teste, estratificado pela variável-alvo para preservar a proporção de classes em ambos os conjuntos.

Etapa 3 — Treinamento

GridSearchCV para tunar três hiperparâmetros do Random Forest, com validação cruzada de 5 folds:

Hiperparâmetro	Valores testados	Significado
n_estimators	100, 200, 500	Número de árvores no ensemble — mais árvores = mais robusto, mais lento
max_depth	None, 10, 20	Profundidade máxima de cada árvore — controla overfitting
min_samples_split	2, 5, 10	Mínimo de amostras para dividir um nó — proteção contra ruído
class_weight	balanced	Compensa eventual desequilíbrio de classes (prenhe vs vazia)
random_state	42 (fixo)	Reprodutibilidade do treinamento

Tempo de treinamento total no cold start: aproximadamente 4 minutos em máquina padrão de desenvolvimento.

Etapa 4 — Avaliação

Modelo avaliado no conjunto de teste com cinco métricas. Critérios mínimos para promoção:

Métrica	Critério mínimo	Observação
Acurácia	> 75%	Métrica geral; pode mascarar desbalanceamento
AUC-ROC	> 0,80	Mede separabilidade das classes
F1-score (PRENHA)	> 0,78	Métrica primária — equilibra precisão e recall
Precisão (PRENHA)	> 0,75	Quantas das predições PRENHA são realmente positivas

Métrica	Critério mínimo	Observação
Recall (PRENHA)	> 0,75	Quantas das prenhezais reais o modelo capturou
Acurácia estratificada por espécie	Sem queda > 5% em qualquer espécie	Anti-viés regional

Modelos que não atingem esses limites não são promovidos a produção.

Etapa 5 — Serialização

O modelo aprovado é salvo em formato joblib (.pkl) junto com os artefatos de pré-processamento (encoders, scaler) e um arquivo de metadados (model_card.json) descrevendo:

- Versão semântica do modelo (rf_v1.0)
- Data de treinamento e tempo total gasto
- Métricas obtidas no conjunto de teste
- Distribuição das features no dataset de treino (médias, desvios, frequências categóricas)
- Hash SHA-256 do dataset usado (rastreadabilidade total)
- Lista de features ativas e suas ordens no vetor de entrada
- Hiperparâmetros vencedores do GridSearchCV

Esses artefatos são versionados em um bucket dedicado, não no repositório de código.

4.2 Estrutura do model_card.json

```
model_card.json
{
  "modelo_versao": "rf_v1.0",
  "tipo": "RandomForestClassifier",
  "framework": "scikit-learn 1.4.0",
  "treinado_em": "2026-05-28T14:32:00Z",
  "treinado_por": "equipe@agrogenia.com",
  "duracao_treinamento_segundos": 247,
  "dataset": {
    "arquivo": "datasets/cold_start_v1.csv",
    "hash_sha256": "a3f1...c4e9",
    "n_registros": 1300,
    "split": { "treino": 1040, "teste": 260 },
    "distribuicao_classes": { "PRENHA": 0.622, "VAZIA": 0.378 }
  },
  "hiperparametros": {
    "n_estimators": 200,
    "max_depth": 10,
    "min_samples_split": 5,
    "class_weight": "balanced",
    "random_state": 42
  },
  "metricas": {
    "acuracia": 0.782,
    "auc_roc": 0.834,
    "f1_prenha": 0.811,
    "precisao_prenha": 0.798,

```

```

    "recall_prenha": 0.825,
    "acuracia_por_especie": {
      "BOVINO": 0.794,
      "OVINO": 0.768,
      "CAPRINO": 0.751
    }
  },
  "features_ativas": [
    "condicao_corporal", "historico_taxa_prenhez", "intervalo_pos_parto_dias",
    "num_partos_anteriores", "dias_desde_ultima_ins", "dep_fertilidade_animal",
    "especie", "raca_femea", "tipo_inseminacao", "protocolo_hormonal",
    "temperatura_ambiente_c", "estacao", "dep_acuracia", "coeficiente_endogamia"
  ]
}

```

4.3 Inferência em produção

No deploy, o microserviço Python carrega o modelo .pkl na inicialização e o mantém em memória. Cada requisição POST chega ao endpoint /predicao, passa pelo pré-processador (com os mesmos encoders salvos no cold start) e é avaliada pelo modelo. Tempo médio de inferência por requisição: 80 a 200 ms, dentro do orçamento de 800 ms previsto para a chamada do backend Java.

Cada predição é registrada em uma tabela de auditoria (tb_predicao_log) com:

- Timestamp UTC da chamada
- animal_id da matriz analisada
- Features de entrada (JSON serializado completo)
- Score retornado (0.0 a 1.0)
- Classificação qualitativa (FAVORAVEL | MEDIO | DESFAVORAVEL)
- Top-5 fatores determinantes com suas contribuições
- modelo_versao usado
- Origem (ml ou rules — registra se houve fallback)
- usuario_id que solicitou a predição

Essa tabela é a base do mecanismo de retroalimentação descrito em 4.5.

4.4 Detecção de drift

Drift estatístico — divergência entre a distribuição dos dados em produção e a do conjunto de treinamento — é monitorado mensalmente. O backend executa um job agendado que:

- Extrai as últimas 200 predições registradas em tb_predicao_log
- Calcula estatísticas descritivas das features (média, desvio padrão, frequência categórica)
- Compara com os parâmetros salvos no model_card.json
- Aplica teste de Kolmogorov-Smirnov para variáveis contínuas (p-valor < 0,05 indica drift)
- Aplica teste qui-quadrado para variáveis categóricas

- Se três ou mais features apresentam divergência significativa, dispara alerta para a equipe de manutenção

4.5 Fluxo de Retroalimentação Contínua

A grande vantagem do AgroGen IA sobre planilhas e cadernos é que cada novo diagnóstico de gestação registrado pelo produtor é, simultaneamente, um label de ground truth para o modelo. O ciclo de retroalimentação opera assim:

Captura do par feature-target

A cada inseminação registrada (endpoint INS-02), o sistema persiste o vetor de features no momento da inseminação (tb_inseminacao + tb_predicao_log se houve consulta prévia à IA). Quando o diagnóstico é registrado (endpoint INS-04), o sistema fecha o par feature-target: a inseminação ganha um campo resultado (PRENHA ou VAZIA), e o registro vira candidato a entrar no próximo dataset de retreinamento.

Gatilho do retreinamento

A cada três meses, ou quando o sistema acumula 500 novos registros completos (o que vier primeiro), dispara-se o retreinamento incremental.

Etapas do retreinamento

Etapa A — Consolidação do dataset

Dataset original do cold start mais todos os pares feature-target reais coletados no período. Os dados reais recebem peso maior (2,0) que os sintéticos do cold start (1,0) na função de perda do treinamento, permitindo que o modelo se ancore progressivamente nos dados de produção. Após acumular 500 registros reais por espécie, o peso dos sintéticos decai progressivamente (de 1,0 para 0,3 ao longo de 24 meses).

Etapa B — Repetição do pipeline

Repete o pipeline completo de treinamento descrito em 4.1 sobre o dataset consolidado, gerando o candidato `v_next`.

Etapa C — Shadow testing

O modelo candidato é deployado em paralelo ao modelo em produção por uma janela de duas semanas. Toda requisição é avaliada por ambos, mas só o modelo de produção responde ao cliente. As predições do candidato são logadas e comparadas com os ground truths que chegam no período.

Etapa D — Decisão de promoção

Se o modelo candidato apresentar métricas (acurácia, AUC, F1) superiores ao de produção em pelo menos 2 pontos percentuais E sem degradação em nenhuma métrica, ele é promovido. Caso contrário, é

descartado e mantém-se a versão anterior. Toda promoção é versionada e registrada em log público no repositório.

Etapa E — Rollback automático

Se em produção o modelo recém-promovido apresentar queda de acurácia superior a 3% em uma janela móvel de 7 dias, o sistema retorna automaticamente para a versão anterior, gerando incidente para a equipe técnica.

4.6 Governança e versionamento

Cada modelo deployado em produção carrega um identificador semântico no formato `modelo_versao = "rf_vX.Y"` presente em todas as respostas da API. Isso permite, quando o produtor reportar uma predição estranha, rastrear exatamente qual modelo gerou aquele resultado e em quais dados ele foi treinado.

Modelos descontinuados são preservados no bucket por pelo menos 18 meses para auditoria. Em caso de questionamento legal ou disputa técnica, é possível reproduzir qualquer predição passada de forma determinística.

Quadro resumo de governança

Aspecto	Política
Versionamento	Semver-like: <code>rf_v{major}.{minor}</code>
Frequência de retreinamento	A cada 3 meses ou 500 novos registros
Janela de shadow testing	2 semanas (estendida a 4 em caso de incidente)
Critério de promoção	+2 pp em métricas-chave, sem degradação em nenhuma
Rollback automático	Queda > 3 pp de acurácia em janela móvel de 7 dias
Retenção de modelos antigos	18 meses mínimo
Aprovação de promoção	Equipe técnica + veterinário consultor
Documentação obrigatória	<code>model_card.json</code> + diff de métricas vs versão anterior

5. Exemplo Prático de Predição (Passo a Passo)

Para tornar o motor concreto, descrevemos o ciclo completo de uma predição real do início ao fim, usando a vaca Mimosa como cenário.

5.1 Cenário

Contexto de uso

O técnico João Silva chega à Fazenda Boa Vista (Crateús-CE) na manhã do dia 5 de junho de 2026. Está calor (29°C). Ele vai inseminar a vaca Mimosa (BOV-0012), uma Nelore de 5 anos, com 3 partos anteriores. Antes de aplicar o protocolo, abre o AgroGen IA no celular e consulta a predição.

5.2 Passo 1 — Seleção do animal e coleta de input

João navega para a aba "Predição de Prenhez" da tela Análise IA (TELA-04). Digita "BOV-0012" no campo de busca. O sistema exibe o card de contexto da Mimosa carregado automaticamente do banco:

Campo	Valor	Origem
Espécie	Bovino	tb_animal
Raça	Nelore (adaptada ao sertão)	tb_dados_geneticos
Sexo / Idade	Fêmea / 5 anos	tb_animal
Status	Ativa	tb_animal
Peso atual	420 kg	última pesagem
Última pesagem	há 15 dias	tb_pesagem
Número de partos anteriores	3	tb_animal.num_partos
Data do último parto	90 dias atrás	tb_animal.data_ultimo_parto
Taxa de prenhez histórica	0,75 (3/4 inseminações)	derivado
Última inseminação	há 35 dias, resultado VAZIA	tb_inseminacao + tb_diagnostico
DEP Fertilidade animal	8,2	tb_dados_geneticos
DEP Acurácia	0,72	tb_dados_geneticos

João preenche os campos situacionais que o sistema não tem:

- Condição corporal atual: 4
- Temperatura ambiente: 29°C
- Tipo de inseminação planejada: IATF
- Reprodutor candidato: Touro Elite 7023 (Angus, DEP Fertilidade 7,5, DEP Acurácia 0,88, sêmen externo da CRV Lagoa)

Clica em "Rodar Predição".

5.3 Passo 2 — Montagem do vetor de features pelo backend

O backend Spring Boot recebe a requisição POST /api/v1/ia/predicao-prenhez. Executa a consulta SQL, deriva as variáveis calculadas e monta o vetor de features:

Vetor de features enviado ao microserviço

```
{
  "especie": "BOVINO",
  "raca_femea": "Nelore",
  "condicao_corporal": 4,
  "num_partos_anteriores": 3,
  "intervalo_pos_parto_dias": 90,
  "historico_taxa_prenhez": 0.75,
  "dias_desde_ultima_ins": 35,
  "ciclos_sem_concepcao": 1,
  "dep_fertilidade_animal": 8.2,
  "dep_fertilidade_reprodutor": 7.5,
  "dep_acuracia_media": 0.80,
  "coeficiente_endogamia": 0.012,
  "heterose_esperada": 4.2,
  "tipo_inseminacao": "IATF",
  "protocolo_hormonal": "P4+EB 7 dias",
  "temperatura_ambiente_c": 29,
  "estacao": "SECA"
}
```

Esse JSON tem aproximadamente 1,2 KB e é enviado ao microserviço Python via POST interno.

5.4 Passo 3 — Processamento pelo Random Forest

O microserviço carrega o vetor, aplica os encoders e o scaler salvos do cold start, e passa o vetor normalizado para o modelo. O Random Forest avalia em 320 árvores e devolve, em 180 ms, a probabilidade média ponderada da classe positiva.

Resultado bruto

Score do modelo: 0,78 (78% de probabilidade de prenhez).

Comparação com o Motor de Regras (sanity check)

Para o caso fictício de o microserviço estar fora do ar, o backend ativaria o fallback. A fórmula seria:

Componente	Cálculo	Subtotal
Probabilidade Base (Bovino)	60%	60
+ condição corporal 4 (ideal)	+10	70
+ intervalo pós-parto 90 dias (≥ 60)	+4	74
+ 3 partos anteriores (faixa 2-4)	+6	80

Componente	Cálculo	Subtotal
+ histórico de prenhez 0,75 ($\geq 0,70$)	+8	88
+ IATF com protocolo válido	+5	93
+ raça adaptada (Nelore)	+4	97
+ heterose esperada 4,2% ($\geq 4\%$)	+4	101
+ soma de DEPs 15,7 (≥ 12)	+6	107
– temperatura 29°C (faixa 29-33)	–2	105
– dias_desde_ultima_ins 35 (≥ 21 , neutro)	0	105
= Soma de deltas	+45 pontos sobre 60%	105% → trunca em 100
+ ruído de realismo	± 2	~78% (após truncamento e ruído)

A convergência dos dois métodos (ML e regras) sobre um valor próximo é justamente o sinal de saúde que o sistema busca. Se houvesse divergência significativa (> 10 pontos percentuais), um alerta interno seria gerado para investigação.

5.5 Passo 4 — Extração de fatores determinantes

O microserviço chama a função de `feature_importance` do Random Forest específica para esta predição (SHAP values) e ordena os top-5 fatores que mais contribuíram para o score:

Fator	Valor atual	Contribuição	Sentido
condicao_corporal	4	+0,18	Positivo
intervalo_pos_parto_dias	90	+0,14	Positivo
historico_taxa_prenhez	0,75	+0,12	Positivo
ciclos_sem_concepcao	1	–0,09	Negativo (ligeiro alerta)
temperatura_ambiente_c	29	–0,06	Negativo (atenção ao estresse calórico)

5.6 Passo 5 — Geração de recomendações

A camada de pós-processamento do backend monta três recomendações textuais a partir de templates pré-definidos preenchidos com os fatores reais:

- "Momento favorável para inseminação. A condição corporal está no nível ideal (4) e o intervalo pós-parto adequado."

- "Atenção à temperatura ambiente (29°C). Realize o procedimento nas horas mais frescas do dia (madrugada ou final da tarde) para reduzir estresse calórico."
- "Priorize reprodutores com DEP de fertilidade $\geq 8,0$. O candidato selecionado (Touro Elite 7023, DEP 7,5) está abaixo do ideal — considere alternativa se disponível."

5.7 Passo 6 — Resposta ao usuário final

A API responde, em 312 ms totais (incluindo overhead de rede e serialização):

Resposta JSON da API

```
{
  "success": true,
  "data": {
    "predicao_id": "uuid-gerado",
    "animal_id": "550e8400-...",
    "score_prenhez": 0.78,
    "score_percentual": 78,
    "classificacao": "FAVORAVEL",
    "fatores_determinantes": [
      { "feature": "condicao_corporal", "impacto": 0.18, "sentido":
"positivo", "valor": 4 },
      { "feature": "intervalo_pos_parto_dias", "impacto": 0.14, "sentido":
"positivo", "valor": 90 },
      { "feature": "historico_taxa_prenhez", "impacto": 0.12, "sentido":
"positivo", "valor": 0.75 },
      { "feature": "ciclos_sem_concepcao", "impacto": -0.09, "sentido":
"negativo", "valor": 1 },
      { "feature": "temperatura_ambiente_c", "impacto": -0.06, "sentido":
"negativo", "valor": 29 }
    ],
    "recomendacoes": [
      "Momento favorável para inseminação...",
      "Atenção à temperatura ambiente (29°C)...",
      "Priorize reprodutores com DEP de fertilidade  $\geq 8,0$ ..."
    ],
    "aviso_clinico": "Este score é uma estimativa probabilística baseada em dados
históricos
e não substitui o julgamento clínico veterinário.",
    "modelo_versao": "rf_v1.0",
    "motor_utilizado": "ml",
    "processado_em_ms": 312
  }
}
```

João decide prosseguir. Clica em "Registrar inseminação", confirma os dados, e a inseminação é gravada com referência ao predicao_id desta consulta. Em 28 dias, quando o diagnóstico de gestação for registrado, esse par feature-target alimentará automaticamente o próximo ciclo de retreinamento.

6. Entregáveis da IA (Outputs)

O motor de IA do AgroGen IA produz três tipos de entrega distintos, expostos em três abas separadas da tela Análise IA (TELA-04). Cada entrega tem objetivo, dados de entrada, formato de saída e SLA próprios.

6.1 Predição de Prenhez (individual)

Atributo	Descrição
Objetivo	Estimar a probabilidade de sucesso de uma inseminação artificial específica antes que ela ocorra, permitindo ao técnico decidir entre prosseguir, adiar ou ajustar o protocolo.
Endpoint	POST /api/v1/ia/predicao-prenhez
Entrada	animal_id selecionado (fêmea com status compatível) + parâmetros situacionais (CC, temperatura, tipo de IA, reprodutor candidato).
SLA	Resposta em até 1 segundo (RNF-04). Tempo médio observado: 300 a 500 ms.

Componentes da saída

- Score numérico de probabilidade no intervalo [0,0 ; 1,0], exibido como gauge circular percentual
- Classificação qualitativa: Favorável ($\geq 70\%$), Médio (50% a 69%) ou Desfavorável ($< 50\%$)
- Top-5 fatores determinantes, cada um com: nome técnico, valor atual da variável, contribuição numérica para o score, sentido positivo ou negativo, e barra de impacto visual
- Três recomendações textuais geradas por templates preenchidos com os fatores reais
- Aviso clínico fixo (não removível): "Este score é uma estimativa probabilística baseada em dados históricos e não substitui o julgamento clínico veterinário."
- Identificador da versão do modelo (modelo_versao) e identificador da predição (predicao_id) para rastreabilidade
- Campo motor_utilizado ("ml" ou "rules") para transparência sobre fallback
- Botão de ação direta: "Registrar inseminação agora" (abre MODAL-03 com dados pré-preenchidos)

6.2 Padrões de Fertilidade (rebanho)

Atributo	Descrição
Objetivo	Revelar padrões de desempenho reprodutivo do rebanho como um todo, permitindo decisões de manejo agregado (quando inseminar, qual protocolo prefere, qual técnico tem melhor taxa).
Endpoint	GET /api/v1/ia/padroes-fertilidade
Entrada	Filtros opcionais de período, espécie, técnico, protocolo. Pré-requisito: mínimo de 20 inseminações com diagnóstico registrado no escopo selecionado.

Atributo	Descrição
SLA	Resposta em até 3 segundos (consulta agregada). Cacheado por 30 minutos por escopo de filtros.

Componentes da saída

- Gráfico de linha temporal: taxa de prenhez por mês nos últimos 12 meses
- Gráfico de barras horizontais: taxa de prenhez agrupada por raça da fêmea
- Gráfico de barras: taxa de prenhez agrupada por técnico responsável
- Gráfico de barras: taxa de prenhez agrupada por protocolo hormonal IATF
- Tabela: top reprodutores por taxa de prenhez gerada (rankeada)
- Insights textuais derivados do clustering K-Means: três a cinco frases descritivas do tipo "Animais com CC entre 3 e 4 inseminados em meses chuvosos têm taxa de prenhez 23% superior" ou "Inseminações realizadas com protocolo P4+EB em fêmeas de 2-4 partos atingem 82% de sucesso"
- Botão "Exportar como PDF" no canto superior

6.3 Seleção Genética (recomendação de cruzamento)

Atributo	Descrição
Objetivo	Recomendar combinações ótimas entre matrizes e reprodutores disponíveis, considerando objetivos de melhoramento e restrições genéticas (consanguinidade).
Endpoint	POST /api/v1/ia/selecao-genetica
Entrada	Seleção pelo usuário de um ou mais objetivos (Ganho de peso / Fertilidade / Rusticidade / Prolificidade) e, opcionalmente, conjunto restrito de matrizes e reprodutores a considerar.
SLA	Resposta em até 2 segundos para conjuntos de até 50 matrizes × 20 reprodutores.

Componentes da saída

Tabela ranqueada de combinações fêmea × macho recomendadas, contendo para cada linha:

- Identificação da matriz (código, nome)
- Identificação do reprodutor (nome, raça, tipo)
- Score genético agregado [0 ; 1] ponderando os objetivos selecionados
- Heterose esperada do cruzamento (percentual)
- Coeficiente de endogamia (F) projetado para a progênie
- Flag de alerta visual destacado em vermelho se $F > 0,0625$
- Justificativa textual curta: "Cruzamento Nelore × Angus maximiza ganho de peso com heterose positiva"
- Tooltip explicativo em cada coluna técnica (DEP, heterose, endogamia) para que produtores menos familiarizados entendam

- Botão "Exportar lista (PDF)" para impressão da recomendação

6.4 Quadro consolidado dos três outputs

Output	Frente	Granularidade	Frequência de uso	SLA
Predição de Prenhez	Decisão tática	Individual (1 animal)	Antes de cada inseminação	≤ 1 s
Padrões de Fertilidade	Análise gerencial	Agregada (rebanho)	Mensal/trimestral	≤ 3 s
Seleção Genética	Planejamento	Múltiplas combinações	Sazonal (planejamento da estação)	≤ 2 s

7. Gestão de Riscos e Mitigação

A introdução de IA em decisões agropecuárias carrega riscos próprios, que esta seção mapeia e endereça. Cada risco tem mitigação explícita planejada antes do deploy.

7.1 Risco técnico — degradação silenciosa do modelo

Risco

Após meses em produção, o modelo pode perder acurácia sem que o usuário perceba, gerando recomendações cada vez piores. As causas mais comuns são drift estatístico (distribuição dos dados muda), mudança no comportamento do produtor após adotar a ferramenta (taxa de prenhez geral muda) ou novos fenômenos não capturados pelas features (ex: ano excepcionalmente seco).

Mitigação

- Monitoramento mensal automatizado de drift via Kolmogorov-Smirnov e qui-quadrado (seção 4.4)
- Janela móvel de 7 dias monitorando a acurácia em produção contra os ground truths que chegam
- Rollback automático se a acurácia cair mais de 3 pontos percentuais
- Retreinamento programado a cada três meses, com promoção controlada por shadow testing
- Alerta para equipe técnica via webhook quando drift atinge três ou mais features simultaneamente

7.2 Risco técnico — indisponibilidade do microserviço de ML

Risco

O microserviço Python (FastAPI) pode ficar offline por falha de deploy, esgotamento de memória ou problema de rede entre o backend Java e o servidor de ML. Sem mitigação, o sistema retornaria erro 503 e o produtor não conseguiria usar a Predição.

Mitigação

- Fallback automático para o Motor de Regras em Java, com timeout de 800 ms na chamada ao microserviço
- Resposta ao cliente inclui o campo motor_utilizado ("ml" ou "rules") para transparência
- Quando o fallback é acionado, o sistema exibe banner discreto: "A análise por IA está temporariamente indisponível. Resultado calculado por motor de regras."
- Alerta para a equipe técnica via webhook quando o fallback é acionado em mais de 5% das requisições por hora
- Health-check do microserviço a cada 30 segundos; em caso de 3 falhas consecutivas, marca como degradado

7.3 Risco de uso de LLM — alucinação e Guardrails

Embora o MVP não utilize LLMs no caminho crítico, é importante endereçar o tema porque versões futuras (v1.1+) podem incluir camada de explicação em linguagem natural, e porque outros engenheiros podem se sentir tentados a "deixar o ChatGPT decidir".

Risco

LLMs podem gerar recomendações tecnicamente plausíveis mas factualmente incorretas, especialmente em domínios técnicos como reprodução animal, onde detalhes específicos (doses, ciclos, protocolos) têm implicações de saúde. Um exemplo de alucinação seria "Use 10 mL de Ivermectina por kg" quando a dose correta é 1 mL/50 kg.

Guardrails obrigatórios em qualquer uso futuro de LLM

Guardrail 1 — Delimitação por templates

LLM nunca gera estrutura nova de resposta — apenas preenche templates pré-aprovados. As frases finais que chegam ao produtor são predefinidas em português técnico revisado por veterinário, e o LLM apenas substitui variáveis (nome do animal, valor do score, nome da feature dominante).

Guardrail 2 — Validação de saída por allowlist

Toda saída de LLM passa por um verificador determinístico que rejeita respostas contendo numerais fora de faixa esperada (doses, datas, dias) ou termos técnicos não pertencentes a um vocabulário controlado.

Guardrail 3 — Separação clara dos canais

Predições numéricas (score, fatores, deltas) JAMAIS são geradas por LLM. São sempre resultado do Random Forest ou do Motor de Regras. LLM, se usado, atua apenas como camada cosmética de explicação, e sua falha não compromete o resultado quantitativo.

Guardrail 4 — Rastreabilidade

Cada resposta gerada por LLM é registrada com o prompt completo, modelo (gpt-4, claude, etc.), versão e parâmetros, para auditoria posterior em caso de queixa.

Guardrail 5 — Opt-out fácil

O produtor sempre pode ver a versão "técnica" sem a camada de explicação por LLM, com um toggle visível.

7.4 Viés nos dados de treinamento

Risco

O dataset de cold start, mesmo calibrado por literatura, pode embutir vieses regionais (sub-representação de caprinos do semiárido, super-representação de bovinos do sudeste). O modelo pode aprender padrões que não se aplicam ao rebanho real do produtor.

Mitigação

- Documentação explícita das fontes do dataset em model_card.json (origem, distribuição por espécie, raça, região)
- Limite de uso do dataset sintético: após coletar 500 registros reais por espécie, o sintético é progressivamente desponderado nas retreinagens (peso decai de 1,0 para 0,3 ao longo de 24 meses)
- Métricas estratificadas: ao avaliar um modelo candidato, calcular acurácia separadamente por espécie. Um modelo que tem acurácia geral alta mas falha em ovinos ou caprinos é rejeitado
- Auditoria periódica do dataset por veterinário consultor, especialmente após retreinamentos

7.5 Risco regulatório e ético — atribuição de responsabilidade

Risco

O produtor pode interpretar a predição como prescrição veterinária, ou pode responsabilizar a plataforma por uma inseminação malsucedida que seguiu recomendação positiva da IA.

Mitigação

- Aviso clínico obrigatório em toda predição — injetado pela camada de pós-processamento e não removível pelo frontend
- Termos de Uso aceitos no cadastro com cláusula específica: "O AgroGen IA é uma ferramenta de apoio à decisão. As recomendações geradas por inteligência artificial têm caráter informativo e não substituem orientação veterinária profissional. O produtor é o único responsável pelas decisões tomadas com base nas informações fornecidas pelo sistema."
- Registro auditável de cada predição (tb_predicao_log) preserva indefinidamente o histórico, permitindo reconstrução exata de qualquer recomendação em caso de questionamento

- Conformidade com LGPD para o tratamento dos dados pessoais envolvidos (RNF-12 a RNF-15)

7.6 Risco de adoção — desconfiança do produtor

Risco

Produtores rurais, especialmente com baixa familiaridade tecnológica, podem desconfiar de uma "caixa-preta" que diz "78% de chance". Sem explicabilidade, o engajamento despenca.

Mitigação

- Apresentação obrigatória dos top-5 fatores determinantes em todo resultado, com linguagem acessível ("Condição corporal ideal", não "CC=4 normalizada")
- Convergência sistemática com o motor de regras: o sistema só exibe predições onde ML e regras concordam dentro de margem de 10 pontos percentuais. Divergências maiores acionam exibição lado-a-lado dos dois resultados, com explicação
- Materiais educativos curtos na tela de Análise IA: "Como funciona a predição?" abre modal explicativo com diagrama simplificado e exemplos
- Recomendações textuais sempre acompanham o número — o score nunca é exibido sozinho

7.7 Plano de contingência em caso de falha sistêmica do modelo

Se acontecer de o modelo, em produção, retornar scores absurdos de forma consistente (ex: todos os animais com 95% ou todos com 5%), o seguinte protocolo é acionado:

Reação	Ação	Disparo
1ª — Rollback imediato	Volta para a versão anterior estável do modelo	Automático: janela móvel detecta anomalia. Manual: equipe técnica via console
2ª — Desativação temporária do ML	Backend força uso do motor de regras. Banner: "Análise por IA temporariamente em manutenção."	Comando manual após avaliação inicial
3ª — Investigação root-cause	Análise dos logs de tb_predicao_log para identificar início do problema, features envolvidas e correlação com eventos (deploy, dados, ataque)	Imediato, em paralelo com 1ª e 2ª reações
4ª — Comunicação proativa	Usuários que receberam predições no intervalo suspeito recebem e-mail com explicação técnica, lista de predições afetadas e orientação para reavaliar decisões	Após identificar janela de impacto
5ª — Retreinamento extraordinário	Novo modelo treinado fora do ciclo normal e submetido a shadow testing estendido (4 semanas)	Após correção do problema raiz

8. Roadmap de Evolução e Apêndices

8.1 Roadmap de evolução do componente de IA

Versão	Marco	Itens-chave
v1.0 — MVP Hackathon (Jun 2026)	Lançamento inicial	Random Forest + Motor de Regras (fallback) · 14 features · cold start de 1.300 registros · três outputs (Predição, Padrões, Seleção Genética)
v1.1 — Q4 2026	Primeira evolução	Reintrodução da feature tecnico_id após acumulação de dados · ajuste fino de deltas com base em telemetria real · MLflow para tracking de experimentos
v1.2 — Q1 2027	Explicabilidade aprimorada	Camada de explicação em linguagem natural com LLM (com guardrails) · "Como funciona a predição?" interativo · gráficos SHAP no UI
v2.0 — Q2 2027	Modelo gradient boosting	Avaliar substituição do Random Forest por XGBoost ou LightGBM com base em métricas reais · A/B test entre arquiteturas
v2.x — A definir	Recursos avançados	Modelo de tempo de vida útil (sobrevida) por matriz · análise de imagem (escore corporal automático) · alertas preditivos de surtos sanitários

8.2 Estrutura recomendada do repositório de IA

Estrutura do repositório		
agrogen-ia-ml/		
├── data/		
│ ├── cold_start_v1.csv		# Dataset sintético inicial
│ ├── synthetic_generator.py		# Script gerador do cold start
│ └── README.md		# Documentação do dataset
├── notebooks/		
│ ├── 01_eda.ipynb		# Análise exploratória
│ ├── 02_baseline.ipynb		# Random Forest baseline
│ ├── 03_hyperparam_tuning.ipynb		# GridSearchCV
│ └── 04_feature_importance.ipynb		
├── src/		
│ ├── preprocessing.py		# Encoders, scaler, validações
│ ├── training.py		# Pipeline de treinamento
│ ├── evaluation.py		# Métricas e estratificação
│ ├── serve.py		# FastAPI app
│ └── monitoring/		
│ ├── drift_detector.py		# KS e qui-quadrado
│ └── feedback_loop.py		# Captura de pares feature-target
├── models/		
│ ├── rf_v1.0.pkl		# Modelo serializado
│ ├── rf_v1.0_preprocessor.pkl		# Encoders e scaler
│ └── rf_v1.0_model_card.json		# Metadados
└── tests/		
│ ├── test_preprocessing.py		
│ └── test_inference.py		

```

├── test_api.py
├── docker/
│   └── Dockerfile
├── requirements.txt
├── pyproject.toml
└── README.md
# FastAPI + scikit-learn

```

8.3 Variáveis de ambiente do microserviço

Variável	Default	Descrição
MODEL_PATH	/app/models/rf_v1.0.pkl	Caminho do modelo serializado
PREPROCESSOR_PATH	/app/models/rf_v1.0_preprocessor.pkl	Encoders e scaler
MODEL_CARD_PATH	/app/models/rf_v1.0_model_card.json	Metadados do modelo
API_PORT	8000	Porta do FastAPI
MAX_INFERENCE_MS	800	Timeout de inferência (alerta interno)
LOG_LEVEL	INFO	DEBUG INFO WARN ERROR
BACKEND_AUTH_SECRET	(secret)	Chave compartilhada com o backend Java

8.4 Contratos de API entre Backend e Microserviço

Endpoint POST /predicao

Recebe vetor de features, retorna score + fatores. Detalhamento completo do contrato:

Campo	Tipo	Obrigatório	Descrição
features	object	Sim	JSON com as 14 features (ver seção 2.4)
predicao_id	string	Sim	UUID temporário para correlação com logs
return_shap	boolean	Não	Default true; se false, omite SHAP values (acelera resposta)

Endpoint GET /health

Health-check para load balancer e monitoramento.

```

Resposta GET /health
{
  "status": "healthy",
  "modelo_versao": "rf_v1.0",
  "modelo_carregado": true,
  "uptime_segundos": 86432,

```

```

"ultima_inferencia": "2026-06-05T10:23:11Z"
}

```

Endpoint GET /model-info

Retorna o conteúdo do model_card.json para auditoria.

8.5 Métricas de monitoramento em produção

Métrica	Cálculo	Alerta
Latência P95	Percentil 95 do tempo de inferência nas últimas 1.000 chamadas	P95 > 800 ms por mais de 5 min
Taxa de fallback	% de chamadas roteadas para o motor de regras na última hora	> 5% em janela de 1 hora
Taxa de erro 5xx	% de respostas com status ≥ 500 na última hora	> 1% em janela de 1 hora
Acurácia em produção (móvel)	Acurácia dos diagnósticos confirmados nos últimos 7 dias vs predição	Queda > 3 pp vs valor de referência do model_card
Drift de features	KS p-valor sobre últimas 200 predições vs distribuição do treino	≥ 3 features com p-valor < 0,05 em janela mensal
Volume de predições	Total de chamadas /predicao por hora	Queda > 50% vs média móvel de 7 dias (indica problema no frontend)

8.6 Glossário técnico

Termo	Definição
Cold Start	Estado inicial de um sistema de ML sem dados reais coletados — exige bootstrap com dados sintéticos ou de literatura
DEP	Diferença Esperada na Progenie — estima quanto a prole de um animal será melhor ou pior que a média da raça em uma característica
Drift	Mudança gradual da distribuição dos dados em produção em relação ao conjunto de treinamento, degradando a acurácia do modelo
Feature Importance	Métrica que indica quanto cada variável de entrada contribuiu para as predições do modelo de ML
Ground Truth	Valor real (rótulo confirmado) usado para avaliar a corretude de uma predição
Guardrails	Restrições determinísticas aplicadas sobre saídas de modelos de IA (especialmente LLMs) para evitar respostas inapropriadas
Heterose / Vigor Híbrido	Superioridade da progênie cruzada em relação à média dos pais puros, expressa em percentual

Termo	Definição
One-Hot Encoding	Transformação de variáveis categóricas em vetores binários (uma coluna por categoria)
Random Forest	Algoritmo de ensemble baseado em árvores de decisão; robusto, interpretável, eficiente em dados tabulares
Shadow Testing	Técnica de validação onde um modelo novo recebe tráfego em paralelo ao modelo atual sem afetar usuários, para comparar performance
SHAP Values	Shapley Additive Explanations — método de explicabilidade que atribui contribuição numérica de cada feature em uma predição específica

8.7 Referências

- BREIMAN, Leo. Random Forests. Machine Learning, v. 45, n. 1, p. 5–32, 2001.
- FACÓ, Olivardo; FERNANDES, Francisco Diogo; LÔBO, Raimundo Nonato Braga. GENECOC — Programa de Melhoramento Genético de Caprinos e Ovinos de Corte: histórico e estado atual. Sobral: EMBRAPA Caprinos e Ovinos, 2011. (Documentos, 101).
- HAFEZ, E. S. E.; HAFEZ, B. Reprodução Animal. 7. ed. Barueri: Manole, 2004.
- LUNDBERG, Scott M.; LEE, Su-In. A Unified Approach to Interpreting Model Predictions. NIPS 2017.
- PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, v. 12, p. 2825–2830, 2011.
- FALCONER, D. S.; MACKAY, T. F. C. Introduction to Quantitative Genetics. 4. ed. Harlow: Longman, 1996.
- BRASIL. Lei nº 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD).
- EXPOAGRO CRATEÚS. Edital nº 01/2026 — Hackathon Expoagro Crateús 2026.

Encerramento

Esta seção encerra a Matriz de IA do AgroGen IA. Toda decisão de arquitetura, scoring, treinamento e governança aqui especificada é normativa para o MVP e ponto de partida para evoluções futuras. Qualquer alteração substancial requer atualização deste documento e aprovação registrada da equipe técnica e do veterinário consultor.